

```
<!--eXplainable Artificial Intelligence-->
```

XAI {

```
<Por="Yovanni Inzunza A." />
```

}



Caja Negra {

La IA moderna (Deep Learning) ha logrado éxitos sin precedentes, pero normalmente su funcionamiento interno es algo complejo, confuso y opaco. Por esta razón se dice que a menudo actúan como “cajas negras” inestructuables.

En sectores críticos como salud, finanzas o defensa, un modelo que no explica su “por qué” genera desconfianza y barreras legales (GDPR)

- Modelos complejos con millones de parámetros.
- Dificultad para auditar decisiones críticas.
- Falta de justificación ante usuarios humanos.

}

¿Qué es XAI? {

La Inteligencia Artificial Explicable busca hacer que el comportamiento de los sistemas IA sea más *inteligible* para los humanos

El *objetivo* no es solo lograr una *alta precisión* predictiva, sino también proporcionar explicaciones que permitan a los usuarios *entender*, *confiar* y *gestionar* mejor estas potentes herramientas.

}

Rendimiento **vs** Explicabilidad {

Existe una tensión histórica en el **Machine Learning**

- **Alta Precisión:** Deep Learning (Baja explicabilidad)
- **Alta Explicabilidad:** Árboles de Decisión (Menor precisión)

XAI busca el “Sweet Spot” o punto óptimo entre rendimiento de aprendizaje y capacidad de explicación.

}

Obstáculos de XAI {

Falta de Evaluación Humana.

Muchos estudios de XAI no evalúan adecuadamente la calidad de las explicaciones que producen, y faltan conjuntos de datos de referencia ("ground-truth datasets") estándar para realizar comparaciones rigurosas.

Además, es crucial evaluar las explicaciones desde la perspectiva de si el usuario las entiende o confía en el sistema, lo que requiere un enfoque interdisciplinario complejo.

Motivaciones Cuestionables.

Mucha de la investigación en XAI se basa en suposiciones que carecen de evidencia sólida, como la idea de que la gente no confía en las "cajas negras" simplemente por ser opacas, o que explicar el funcionamiento interno de un modelo automáticamente aumentará la confianza del usuario.

En realidad, no está claro si los usuarios necesitan conocer el funcionamiento interno para confiar en la IA.



}

Saliency Maps (Vision) {

¿Cómo ve la IA?

Utilizados principalmente en visión computacional. Resaltan los píxeles o regiones de una imagen que más influyeron en la predicción.

Importancia: Permite validar si un diagnóstico médico se basó en el área correcta de una radiografía.



}


LIME {

Explicaciones Locales

LIME (Local Interpretable Model-agnostic Explanations) perturba los datos de entrada para ver cómo cambia la predicción en una muestra específica.

Supuestamente puede explicar CUALQUIER modelo de caja negra aproximándolo localmente con un modelo lineal simple.

LIME with Text data



}


SHAP {

El Estándar matemático

Basado en los "Valores de Shapley" de la Teoría de Juegos. Reparte el crédito de la predicción de forma justa entre todas las variables.

SHAP (SHapley Additive exPlanations) ofrece una base matemática sólida para la atribución de características.

- **Consistencia:** Si una variable aporta más, su valor SHAP sube.
- **Global y Local:** Explica una sola predicción o el modelo entero.



}



Fuentes {

- Weber, R. O., Johs, A. J., Goel, P., & Silva, J. M. (2024). XAI is in trouble. AI Magazine, 45(3), 300–316. <https://doi.org/10.1002/aaai.12184>
- Gunning, D., Stefik, M., Choi, J., Miller, T., Stumpf, S., & Yang, G. (2019). XAI—Explainable artificial intelligence. Science Robotics, 4(37). <https://doi.org/10.1126/scirobotics.aay7120>
- Owens, E., Sheehan, B., Mullins, M., Cunneen, M., Ressel, J., & Castignani, G. (2022). Explainable Artificial intelligence (XAI) in insurance. Risks, 10(12), 230. <https://doi.org/10.3390/risks10120230>

}

```
<!--Cesar Yovanni Inzunza Aguilar-->
```

Gracias {

```
<Por="Su atención :)" />
```

}

